

2026 中国高校计算机大赛—人工智能创意赛

昇腾赛道项目创意书（复赛）

说明：本文件为创意书正文。带【待填】/【待确认】的字段必须由团队按官网报名信息补齐；交付件格式为 PDF，命名格式：作品名称+参赛队伍名称.pdf。

参赛学校：哈尔滨工业大学【待确认：须与官网报名一致】

团队名称：零秒识危【待确认：10 个字符以内、勿用标点，须与官网报名一致】

作品名称：昇腾智迁——Qwen3.5 自动迁移 Skill【待确认：30 个字符以内，须与官网报名一致】

赛题方向：昇腾赛道 · 主流大模型优化创新（模型迁移 + 性能优化 + 场景创新）

联系人（队长）：靳松【待确认】

联系电话（队长）：【待填：队长手机号】

参赛团队信息表

注：参赛团队的报名信息须与官网报名信息保持一致。

项	内容
作品名称	昇腾智迁——Qwen3.5 自动迁移 Skill【待确认：以官网报名为准】
团队名称	零秒识危【待确认】
参赛学校	哈尔滨工业大学（以队长学校为准）【待确认】

团队队员基本信息

姓名	学校全称	院（系）全称	专业全称	年级	毕业时间	联系电话	邮箱	团队分工
靳松	【待填：学校全称】	【待填：院系全称】	【待填：专业全称】	【待填：年级】	【待填：毕业时间】	【待填：手机】	【待填：邮箱】	队长
杜文琦	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	队员
方佳乐	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	队员
朴学峰	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	【待填】	队员

团队指导教师信息（指导老师须与队长同校）

姓名	院（系）全称	职称	研究方向	联系电话	联系邮箱
【待填：指导教师姓名】	【待填：院系】	【待填：职称】	【待填：研究方向】	【待填：电话】	【待填：邮箱】

团队成员优势描述

本团队由 4 名成员组成，分工覆盖本作品的全部关键环节：环境与版本适配、模型迁移点分析与方案生成、训练与性能优化、判定链与证据复现。团队在本次复赛中独立完成了从零环境搭建、官方并行几何复刻、八级性能优化与精度判定链构建，并沉淀了 136 条可复核的工程坑表与一整套自动化闸门。【请按实际情况修改本段：突出与本作品相关的课程/项目/竞赛经历】

【待填：第二段可写团队协作方式、时间投入、与昇腾生态相关的经历】

项目原创性声明

《昇腾智迁——Qwen3.5 自动迁移 Skill》作品原创性声明【作品名待确认】

本参赛作品由本团队独立研究完成。作品中的自动迁移流水线设计、判定链工具、环境冗余矩阵与全部实测数据均出自本团队工作；除文中注明引用的官方文档、开源框架与公开资料外，不包含其他个人或集体已发表的成果。本声明的法律责任由本参赛队承担。

参赛队员签名（团队全部成员）：【待手写签名：靳松、杜文琦、方佳乐、朴学峰】

日期：【待填】 年 【待填】 月 【待填】 日

指导老师审核签名：【待手写签名】

日期：__ 年 __ 月 ____ 日

作品说明文档（复赛）

一、创意描述

一句话创新点：我们交付的不是“改好的模型”，而是“会改模型的流程”——一套面向昇腾算力的自动迁移 Skill：输入模型源码与目标环境，自动完成迁移点识别、迁移方案生成、算子验证、数据与权重准备、训练执行、性能基准与精度判定，把大模型向国产算力迁移从“专家逐行读源码的手工活”变成可复用、可复现、证据可溯源的自动化流水线。

成效（本队实测）：在 1× 昇腾 910C 双 die 上完成 Qwen3.5-0.8B 迁移，单步训练耗时 21,393 ms → 419.0 ms (51.1×)；官方口径 50-100 步窗口中位 419.0 ms（官方参考基线 431.3 ms，同口径平价；该数值绑定 2026-09-10 的运行时段，详见性能测试报告）。精度上第 1 步 loss 与官方逐位一致 (1.924621 = 1.924621)，100 步逐点误差超 2% 的步数为 0；裁决为 NEEDS EVIDENCE（黄）——两道证据门（官方数据字节、样本序）按构造未闭合，不宣称已验证/达标。

二、需求与市场价值

2.1 用户需求贴合度

行业痛点：大模型结构迭代速度已远快于专用芯片的算子适配速度。以 Qwen3.5 引入的 GatedDeltaNet（线性注意力）、视觉 3D-Conv patch embedding 等新结构为例，它们在昇腾平台上没有现成实现，传统迁移依赖专家逐行阅读源码、手工替换算子、逐层调试验证——不可复用、不可复现、不可规模化。国产算力生态最缺的往往不是硬件，而是把模型搬上硬件的工程效率。

我们的解法：把迁移过程本身工程化。本队在该场景下完成了端到端验证：面对一个昇腾生态尚无现成实现的新模型结构，从零环境到跑通 100 步训练、再到精度逐位对齐与 51 倍性能优化，全程由流水线驱动、每步产物落盘可复核。

2.2 市场价值及推广性

可泛化：迁移点识别规则外置为模型档案（profiles/<model>.json），AST 扫描器与流水线通用；冗余设计使同一套流程可在有卡/无卡、单卡/多卡、不同芯片型号、不同 CANN 与 torch 版本组合下自动选择执行路径——这解决了国产算力环境碎片化的现实问题。

应用场景：迁移后的 Qwen3.5-0.8B 接入工业“操作规范（SOP）判定”场景——从监控画面判断操作手法是否合规（例如法兰螺栓是否采用对角交叉顺序紧固），输出结构化 JSON（compliant / step / issue / evidence / bbox / confidence）。该判定需要“语义 + 动作时序 + 常识推理”三重能力，传统 CV 小模型难以替代，而昇腾边缘盒子/一体机的私有化部署形态天然适配工厂场景。

推广模式：① 开源 Skill 全量（含判定链与坑表）→ ② 向上游 MindSpeed-MM 提交 PR（贡献 0.8B 示例配置与版本配对说明）→ ③ 面向昇腾生态 ISV 与工业质检厂商提供“迁移即服务”的私有化落地。潜在合作对象包括昇腾生态解决方案商、工业视觉集成商与高校科研团队。

三、技术方案

3.1 功能架构与技术流程

Skill 采用八阶段流水线，上一步产物即下一步输入，全程证据落盘：

P0 环境探测 → P1 迁移点识别 → P2 方案与配置生成 → P3 算子/契约验证
→ P4 权重与数据准备 → P5 训练执行 → P6 性能基准 → P7 精度判定

env.json	points.json	plan.md+cfg	ops.json
assets.json	train.log	bench.json	verdict.json

各阶段职责：P0 探测 NPU/芯片/die 数/软件版本，决定执行路径与配置档；P1 用 AST 静态解析建模源码，程序化输出迁移点矩阵（带行号与符号）；P2 将迁移点映射为 MindSpeed-MM 落点，并按环境自动生成训练配置（几何/显存策略/算子后端）；P3 验证算子 forward 与 shape 契约（有卡时增补 CPU↔NPU 数值一致性）；P4 准备权重（HF→DCP）与数据（官方同源管线，含字节级校验）；P5 执行训练并自动诊断常见故障；P6 按官方口径（50 - 100 步）产出性能数据；P7 机器判定配置一致性与精度对齐，输出 verdict_id 并写入哈希链账本。

3.2 功能与技术使用关系

功能点	技术应用（具体技术点）	进展
环境探测与路径决策	npu-smi 解析芯片/die 数；torch_npu 导入探针；triton-ascend backend 与最小 kernel 实测；版本矩阵自动选源	已完成（实测于 910C 双 die，正确识别并给出配置档）
迁移点识别	Python AST 静态分析，4 类规则（GDN 线性注意力 / 全注意力 / 视觉 3D-Conv / 自定义激活归一化）；对 transformers v5.2.0 真实源码命中 49 处	已完成（初赛实现，复赛沿用）
迁移方案与配置生成	迁移点 → MindSpeed-MM 落点映射；按环境矩阵生成训练配置（含逐字段回读校验，失败即报错而非静默跳过）	已完成
算子与契约验证	算子矩阵 forward/shape 验证；无本地实现者标 contract-only 不伪造；CPU↔NPU 一致性核对	已完成（GDN 已在 NPU Triton 上真跑通，日志 0 次回退 CPU）
数据与权重管线	ModelScope 同源下载；官方转换脚本；字节级校验锚点（LLaVA json 228,941,895 B / 产物 157,712 样本）；HF→DCP 转换	已完成
训练执行与故障诊断	torchrun 双 die 并行；必备环境变量自动注入；7 类故障模式自动诊断并给出处置	已完成（100 步完整跑通）
性能优化	profiling 定位 launch-bound 瓶颈；八级单变量优化（算子实现 / 几何 / 硬件 / 显存策略 / 通信）	已完成（51.1×，50 - 100 步优于官方基线）
精度判定	7+2 维配置指纹比对 + 可达性谓词 + 五态裁决 + append-only 哈希链账本；0-GPU 可复核	已完成（配置零偏离、逐点 0/100 超 2%）
跨环境冗余	6 维降级矩阵（有无 NPU / 芯片型号 / 单双卡 / 版本组合 / 算子后端 / 数据规模），每维含降级路径与诚实标注	已完成（无卡环境实测降级正常）
场景应用（SOP 判定）	视觉 3D-Conv 建模动作过程；语义+时序+常识三重推理；结构化 JSON 输出契约	初步验证（已定义契约与依赖门槛，待端到端闭环）

3.3 关键技术实现过程（创新点展开）

创新点一：把“迁移范围”变成可审计的程序化输出。迁移对象不是人工拍脑袋圈定的，而是解析器对真实建模源码扫描所得的 49 处命中（带行号、带符号）。这使得迁移范围可审计、可增量更新，也为后续适配其他模型提供了规则化基础。

创新点二：用“几何可比性”而非“统计巧合”来证明精度对齐。我们发现：官方参考日志运行在 2 个 die 上、每 die 每步 4 个样本；若单卡一次跑 8 个样本，每步的 batch 组成与官方物理上不同，逐点对比必然失真。经 npu-smi 实测确认本机为 1 张 910C 双 die 卡（单卡 2 芯片、合计 128GB），与官方拓扑一致，由此完整复刻官方并行几何。结果是第 1 步（纯前向，学习率为 0）的 loss 与官方逐位相同——这同

时证明了 权重、前 8 个样本的内容与顺序、算子数值实现三者均与官方一致，比任何统计指标都更强。

创新点三：用“瓶颈量化”驱动优化，而非盲目调参。profiling 实测每步约 1.4 万个 kernel 发射、计算仅占 stage 时间的 23%，由此判定瓶颈是 kernel 发射次数而非算力，进而得到关键杠杆：kernel 数正比于 micro-batch 个数。沿此思路完成八级优化，每级只改一个变量、收益均可在日志中复核。过程中还得到三个反直觉结论：为旧小显存环境设置的省显存开关在 128GB 卡上纯属开销（关闭后 step1 loss 逐位不变）；FSDP 预取深度加深反而变慢；pregather 可消除周期性长尾慢步。

创新点四：让“精度是否达标”由机器裁决，而非人工宣称。判定链对 7+2 维配置做指纹比对，输出可达性级别与五态裁决，并以哈希链账本固化 verdict_id（账本任何篡改或重排都会在校验时被检出）。该链纯 CPU、0-GPU 可完整复现，评委在无昇腾硬件的机器上也能复核我们的结论。

四、排期规划

阶段	时间	目标	状态
环境与基线	08/27 - 09/06	算力就绪、MindSpeed-MM 跑通、官方基线数据对齐	✅ 完成
迁移打通	09/07	910C 双 die 全链迁移；复刻官方并行几何；精度逐位对齐	✅ 完成
性能优化	09/07 - 09/10	八级优化至 51.1×，50 - 100 步优于官方基线	✅ 完成
Skill 化	09/11	八阶段流水线整合 + 6 维冗余降级 + 自检	✅ 完成
交付物成型	09/11 - 09/20	创意书、四份报告、日志、Skill 与源码包	📁 进行中
场景闭环	09/20 - 09/27	工业 SOP 判定端到端演示（AI 推理 + JSON 输出）	📁 待办
提交与缓冲	09/28 - 09/30	全量自查、提前提交，留 2 天缓冲	📁 待办

落地转化计划：复赛后将 Skill 开源并向上游 MindSpeed-MM 提交 PR（0.8B 示例配置、triton-ascend 版本配对说明），同时以工业 SOP 判定场景为切入点，与昇腾生态伙伴推进私有化试点。

五、最小可运行 demo

形态：命令行 Skill 包（qwen35-ascend-migrator），含脚本、配置与真实运行示例产物。

无昇腾硬件也能跑的部分（评委可 5 分钟内验证）：

```
python3 selfcheck.py          # 三层自检 → SELF CHECK_OK
python3 scripts/70_judge.py --log examples/train/train.log \
    --baseline officialB --baseline-log examples/train/official_baseline.log --
out out/judge
# 输出：逐点误差、窗口偏差、verdict (level=pointwise_feasible)
```

有昇腾硬件时的完整链路：

```
python3 scripts/00_probe_env.py          # P0 探测 → 路径与配置档
python3 scripts/20_plan_migration.py      # P2 生成训练配置
python3 scripts/50_train.py              # P5 训练 100 步
python3 scripts/60_bench.py --log out/train/train.log  # P6 性能数据
python3 scripts/70_judge.py --log out/train/train.log --baseline officialB  #
P7 判定
```

附：功能点与技术应用汇总表

见 § 3.2。
